

# 邵佳琪

PhD, HKUST | Expected Graduation: June 2027

Target: LLM Agent / RL / Agent Systems

[GitHub](#) [个人主页](#) [✉ jshaoaj@connect.ust.hk](mailto:jshaoaj@connect.ust.hk) [Google Scholar](#)

## 教育背景

### 香港科技大学

电子与计算机工程博士 (PhD)

2023 年秋季-至今

- 导师: 张薇教授 (香港科技大学) (长期合作老师: 罗冰教授 (昆山杜克大学))

### 香港中文大学 (深圳)

电子与计算机工程学士 专业方向: 计算机工程

2019 -2023

## 研究方向

我的研究聚焦 **AI Agent 的可信评测与评测基础设施**, 核心关注 benchmark 分数能否真实反映 Agent 的目标能力。围绕结果之外的**过程可靠性**、**评测协议有效性与评测规模化**, 构建覆盖执行轨迹与评测环境的系统化评测方法: 通过 **SeekBench** 将评测从最终准确率扩展至证据收集、错误恢复与置信校准等认知过程; 通过 **HackDetect** 分析评测暴露与 reward hacking 对分数有效性的影响; 进一步将相关方法沉淀为统一的 benchmark 接入与交付规范, 为后续扩大任务规模、接入更多 Agent 及自动化评测奠定基础。

## 实习经历

### 腾讯混元大模型团队 | 高级研究员 (青云实习计划)

#### RSI 评估与评测范式研究

2026 年 5 月-至今

- Reward Hacking 检测与评测安全**: 建立“暴露 → 利用 → 失真” (Expose→Exploit→Mislead) 分析框架, 系统归纳 benchmark 侧暴露面 taxonomy; 设计 L0-L3 评测安全等级与自动化 hack 检测规则, 沉淀 benchmark 上线前审计 checklist。相关成果形成第一作者论文 [HackDetect](#)。
- RSI 评测体系 0→1 建设**: 负责递归自我改进 (RSI) 评测体系从零构建, 组织 8 大研究领域评测任务调研, 对标 OpenAI Self-Improvement Suite, 将评测对象从最终分数扩展至研究过程与协议有效性; 制定覆盖 evaluator 隔离、hidden set 设计及 invalid/hack 判定的 benchmark 接入与交付标准, 统一多来源任务的交付语义与评测口径, 支撑分数可比、任务可组合与审计自动化, 为评测规模从数十项扩展至数百项构建可持续演进的基础设施。

### 字节跳动 | 算法实习生 (长程智能体系统)

#### 系统设计与实现

2026 年 1 月-2026 年 5 月

- 端到端负责长程智能体系统的设计与落地, 面向复杂任务中的持续执行、自迭代优化与人工介入需求。
- 构建统一运行框架, 将持续执行、过程评估与迭代优化闭环联结起来, 支撑长时程智能体行为的稳定运行。
- 支持 **自主执行** / **交互协同** / **人工接管** 三种运行模式, 提升系统在自主运行与人机协同场景下的可控性。
- 建立异常恢复与人工接管机制, 增强系统在长时程运行中的鲁棒性、可靠性与可部署性。

## 代表性研究成果

### 1. SeekBench: 面向搜索智能体认知能力的标准化评测基准

**第一作者** | 基准设计与评估方法论

[\[论文链接\]](#)

技能: **基准设计** **评估方法论** **轨迹级评测**

ICLR 2026

- 开发 **SeekBench** 标准化评测基准，用于系统评估搜索型大语言模型智能体的认知能力，而不仅仅停留在最终任务准确率层面。
- 提出并落地轨迹级评测范式，使智能体评测从“结果是否正确”扩展到“过程是否可靠”。
- 定义三个核心指标——推理可靠性（Groundedness）、恢复性（Recovery）和校准性（Calibration）——量化评估证据整合、低质量信息恢复与基于证据的决策能力。

## 2. Scale-Conditioned Agent Memory: 智能体记忆的规模条件评测

第一作者 | 评测协议设计与系统实验

arXiv, 2026

[\[论文链接\]](#)

技能: Agent Memory 规模条件评测 轨迹诊断

- 识别固定快照准确率无法衡量记忆随无关会话累积是否仍可用，提出 evidence-preserving growth 的规模条件评测协议：固定任务证据并逐步增加无关会话，从预算约束可靠性、尾部调用开销、失败模式及可用规模边界四个维度进行诊断。
- 在 LongMemEval、LoCoMo 及 flat / planar / hierarchical 三类记忆接口上完成系统评测，揭示可扩展记忆能力取决于 Agent、接口、规模区间与交互预算；HippoRAG 的预算约束可靠性随无关会话增长下降 16–20 个百分点。

## 3. FoldAct: 面向长程大语言模型智能体的稳定优化方法

第一作者 | 算法设计与长程优化

arXiv, 2025

[\[论文链接\]](#)

技能: 智能体强化学习 长程优化 上下文折叠

- 识别出长程搜索智能体多轮强化学习难以扩展的核心瓶颈，在于摘要策略随训练持续更新所引发的训练非平稳性，而非单纯的上下文长度限制。
- 据此提出 **FoldAct** 上下文折叠优化框架与结构化折叠训练流程，在控制上下文长度的同时稳定折叠策略学习并提升训练效率。
- 在复杂搜索智能体任务上实现最高 **5.19 倍** 训练加速，并保持长程决策质量，验证上下文折叠是长程智能体优化中的有效扩展路径。

## 4. MorphAgent: 自演化多智能体协作算法

共同第一作者 | 系统架构与自适应协作

ICML-MAS, 2025

[\[论文链接\]](#)

- 设计去中心化、自适应的协作机制，使大语言模型智能体能够在没有预定义结构的情况下动态演化角色。
- 构建自演化协作框架，在推理与代码生成基准上提升任务表现、迁移能力与鲁棒性。

## 5. 昆山杜克大学科研助理

研究指导

2025 年 2 月-2026 年 1 月

- 搭建学生科研推进机制，覆盖选题设计、系统实现、实验组织与论文写作，并指导 **10 余名本科生** 开展大语言模型叙事系统、记忆机制与人机协作相关研究。
- 组织与 Duke 相关合作伙伴的交流展示活动，包括项目汇报与论坛展出，推动跨机构合作交流与团队协同。

## 6. MASArena: 多智能体系统基准测试框架

主要负责人 | 系统架构与评测基础设施

2025 年 5 月-2025 年 7 月[\[项目链接\]](#)

- 识别出多智能体研究中评测流程碎片化、实验复现困难与跨系统横向比较失真的关键系统瓶颈，并据此抽象统一评测 workflow。
- 从零主导 MASArena 开源评测框架的架构设计与实现，统一单智能体与多智能体系统的任务执行、实验编排、结果管理与可视化分析流程。
- 构建可扩展、可复用的评测基础设施，支持不同智能体、工具与数据集上的标准化比较，显著提升评测的可重现性与可解释性。[\[代码贡献\]](#)

## 其他研究 & 项目

Beyond Right to be Forgotten: Managing Heterogeneity Side Effects Through Strategic Incentives

第一作者 | 激励机制设计与理论分析

ACM MobiHoc 2025

技能: 联邦遗忘 激励机制设计 博弈论 理论分析

- 研究联邦遗忘在非独立同分布数据场景下的异质性副作用: 移除指定客户端后, 与其数据分布相近的剩余客户端会遭受更严重的性能退化, 并进一步削弱系统稳定性与参与意愿。
- 构建刻画异质性影响的理论框架, 并将联邦遗忘建模为服务器与客户端之间的 Stackelberg 博弈, 通过支付激励保留关键客户端; 方法可将全局稳定性提升至多 6.23%, 将最差客户端退化降低 10.05%, 并较完全重训练获得最高 38.6% 的运行效率提升。

FedCampus / FedKit: 面向智慧校园的跨平台联邦学习系统

- 构建融合联邦学习与差分隐私的智慧校园真实移动应用, 并开发支持 Android 和 iOS 的跨平台联邦学习流水线, 覆盖模型转换、硬件加速训练与端侧聚合; 系统已在昆山杜克大学完成 100 个定制智能手表及 Android/iOS 客户端部署, 相关工作被 IEEE INFOCOM 2024 Demo 接收。

## 教学经历

助教

- ELEC3120: 计算机通信网络 (香港科技大学, 2024 年春季)
- ELEC3300: 嵌入式系统导论 (香港科技大学, 2024 年秋季)
- 向量空间方法与应用 | ECE 586K (昆山杜克大学, 2025 年春季)