

邵佳琪

PhD, HKUST | Expected Graduation: June 2027

Target: LLM Agent / RL / Agent Systems

[GitHub](#) [个人主页](#) [✉ jshaoaj@connect.ust.hk](mailto:jshaoaj@connect.ust.hk) [Google Scholar](#)

教育背景

香港科技大学

电子与计算机工程博士 (PhD)

2023 年秋季-至今

- 导师: 张薇教授 (香港科技大学) (长期合作老师: 罗冰教授 (昆山杜克大学))

香港中文大学 (深圳)

电子与计算机工程学士 专业方向: 计算机工程

2019 -2023

研究方向

我的研究聚焦长程 Agent 任务的可信评测与可靠执行。首先,针对现有评测只能判断终结果、无法评估 Agent 在长程交互中的认知能力的问题,提出 **SeekBench** (ICLR 2026),从证据收集、错误修正、置信校准三个维度建立过程评测标准;同时建立 **Harness Eval** 框架,通过”控制模型变量、隔离 Core 差异”的方法论定义四级长程任务协议 (单轮工具链 → 多轮迭代 → 跨会话持久 → 自主长程),并构建 reward hacking 五层防御体系 (Prevent Access / Inference / Specialization / Evaluator Exploit / Detection),保障长程评测的可信性。在此基础上,评测标准暴露出 Agent 在长时运行中的可靠性缺口,设计可恢复、可介入、可持续的智能体执行框架。

实习经历

腾讯混元大模型团队 | 高级研究员 (青云实习计划)

RSI 评估与评测范式研究

2026 年 5 月-至今

- 建立”暴露 → 利用 → 失真” (Expose→Exploit→Mislead) 的 **reward hacking 分析模型**,通过 8+ 个真实案例的代码级审计 (NAS 查表、cache 刷分、hidden 数据泄漏等) 归纳 benchmark 侧暴露面 taxonomy。设计 L0-L3 安全等级与自动化 hack 检测规则,落地为 benchmark 上线前审计 checklist。
- 负责研究型 Agent 未来评测体系的思考与构建。针对”AI 自我改进 (RSI)” 缺乏可信度量的问题,组织完成 8 大研究领域 20+ 个主流 benchmark 的系统调研与接入决策,提出 R0-R4 五级能力分级与配套证据标准;将评测从”一次性跑分” 重构为覆盖任务设计、执行、测量、归一化、反馈、能力主张的 **六环节评测链路**,配套 hidden-test 成熟度模型与上线前完整性审计标准,使分数成为可辩护的能力证据。

字节跳动 | 算法实习生 (长程智能体系统)

系统设计与实现

2026 年 1 月-2026 年 5 月

- 端到端负责长程智能体系统的设计与落地,面向复杂任务中的持续执行、自迭代优化与人工介入需求。
- 构建统一运行框架,将持续执行、过程评估与迭代优化闭环联结起来,支撑长时程智能体行为的稳定运行。
- 支持 **自主执行 / 交互协同 / 人工接管** 三种运行模式,提升系统在自主运行与人机协同场景下的可控性。
- 建立异常恢复与人工接管机制,增强系统在长时程运行中的鲁棒性、可靠性与可部署性。

代表性研究成果

1. SeekBench: 面向搜索智能体认知能力的标准化评测基准

第一作者 | 基准设计与评估方法论

ICLR 2026

[\[论文链接\]](#)

技能: **基准设计** **评估方法论** **轨迹级评测**

- 开发 **SeekBench** 标准化评测基准，用于系统评估搜索型大语言模型智能体的认知能力，而不仅仅停留在最终任务准确率层面。
- 提出并落地轨迹级评测范式，使智能体评测从“结果是否正确”扩展到“过程是否可靠”。
- 定义三个核心指标——推理可靠性（Groundedness）、恢复性（Recovery）和校准性（Calibration）——量化评估证据整合、低质量信息恢复与基于证据的决策能力。

2. FoldAct: 面向长程大语言模型智能体的稳定优化方法

第一作者 | 算法设计与长程优化

arXiv, 2025

[\[论文链接\]](#)

技能: **智能体强化学习** **长程优化** **上下文折叠**

- 识别出长程搜索智能体多轮强化学习难以扩展的核心瓶颈，在于摘要策略随训练持续更新所引发的训练非平稳性，而非单纯的上下文长度限制。
- 据此提出 **FoldAct** 上下文折叠优化框架与结构化折叠训练流程，在控制上下文长度的同时稳定折叠策略学习并提升训练效率。
- 在复杂搜索智能体任务上实现最高 **5.19 倍** 训练加速，并保持长程决策质量，验证上下文折叠是长程智能体优化中的有效扩展路径。

3. MorphAgent: 自演化多智能体协作算法

共同第一作者 | 系统架构与自适应协作

ICML-MAS, 2025

[\[论文链接\]](#)

- 设计去中心化、自适应的协作机制，使大语言模型智能体能够在没有预定义结构的情况下动态演化角色。
- 构建自演化协作框架，在推理与代码生成基准上提升任务表现、迁移能力与鲁棒性。

4. 昆山杜克大学科研助理

研究指导

2025 年 2 月–2026 年 1 月

- 搭建学生科研推进机制，覆盖选题设计、系统实现、实验组织与论文写作，并指导 **10 余名本科生** 开展大语言模型叙事系统、记忆机制与人机协作相关研究。
- 组织与 Duke 相关合作伙伴的交流展示活动，包括项目汇报与论坛展出，推动跨机构合作交流与团队协作。

5. MASArena: 多智能体系统基准测试框架

主要负责人 | 系统架构与评测基础设施

2025 年 5 月–2025 年 7 月[\[项目链接\]](#)

- 识别出多智能体研究中评测流程碎片化、实验复现困难与跨系统横向比较失真的关键系统瓶颈，并据此抽象统一评测 workflow。
- 从零主导 **MASArena** 开源评测框架的架构设计与实现，统一单智能体与多智能体系统的任务执行、实验编排、结果管理与可视化分析流程。
- 构建可扩展、可复用的评测基础设施，支持不同智能体、工具与数据集上的标准化比较，显著提升评测的可重现性与可解释性。[\[代码贡献\]](#)

其他研究 & 项目

Beyond Right to be Forgotten: Managing Heterogeneity Side Effects Through Strategic Incentives

第一作者 | 激励机制设计与理论分析

ACM MobiHoc 2025

技能: **联邦遗忘** **激励机制设计** **博弈论** **理论分析**

- 研究联邦遗忘在非独立同分布数据场景下的异质性副作用：移除指定客户端后，与其数据分布相近的剩余客户端会遭受更严重的性能退化，并进一步削弱系统稳定性与参与意愿。
- 构建刻画异质性影响的理论框架，并将联邦遗忘建模为服务器与客户端之间的 Stackelberg 博弈，通过支付激励保留关键客户端；方法可将全局稳定性提升至多 6.23%，将最差客户端退化降低 10.05%，并较完全重训练获得最高 38.6% 的运行效率提升。

FedCampus / FedKit: 面向智慧校园的跨平台联邦学习系统

- 构建融合联邦学习与差分隐私的智慧校园真实移动应用，并开发支持 Android 和 iOS 的跨平台联邦学习流水线,覆盖模型转换、硬件加速训练与端侧聚合;系统已在昆山杜克大学完成 **100** 个定制智能手表及 Android/iOS 客户端部署，相关工作被 **IEEE INFOCOM 2024 Demo** 接收。

■ 教学经历

助教

- ELEC3120: 计算机通信网络 (香港科技大学, 2024 年春季)
- ELEC3300: 嵌入式系统导论 (香港科技大学, 2024 年秋季)
- 向量空间方法与应用 | ECE 586K (昆山杜克大学, 2025 年春季)